

Università di Napoli Federico II – Scuola Politecnica e delle Scienze di Base
Corso di Laurea Magistrale in Ingegneria Informatica



Corso di Algoritmi e Strutture Dati

Ordinamento in tempo lineare

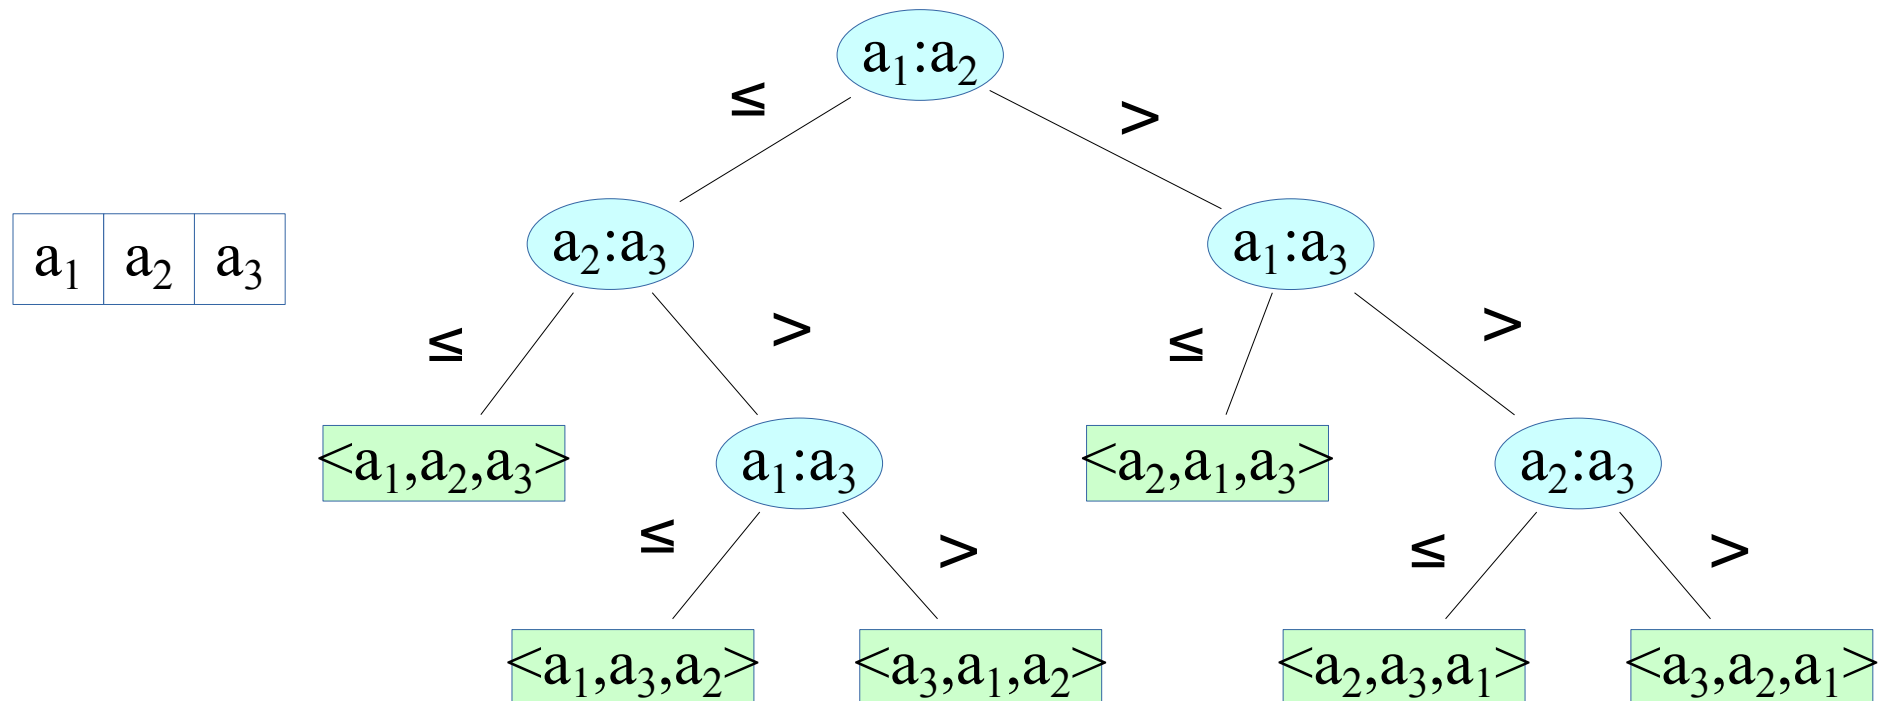


- Gli algoritmi di ordinamento che abbiamo visto sono basati sul confronto tra elementi (***comparison sort***)
- Dimostriamo che, per algoritmi basati sul confronto, nel caso peggiore sono necessari $\Omega(\lg n)$ confronti per ordinare n elementi
- Merge sort e heap sort sono asintoticamente ottimi
- Quick sort invece nel caso peggiore ottiene $\Theta(n^2)$
- Vedremo anche algoritmi, **non** basati sul confronto, che richiedono un tempo lineare

Algoritmi di ordinamento



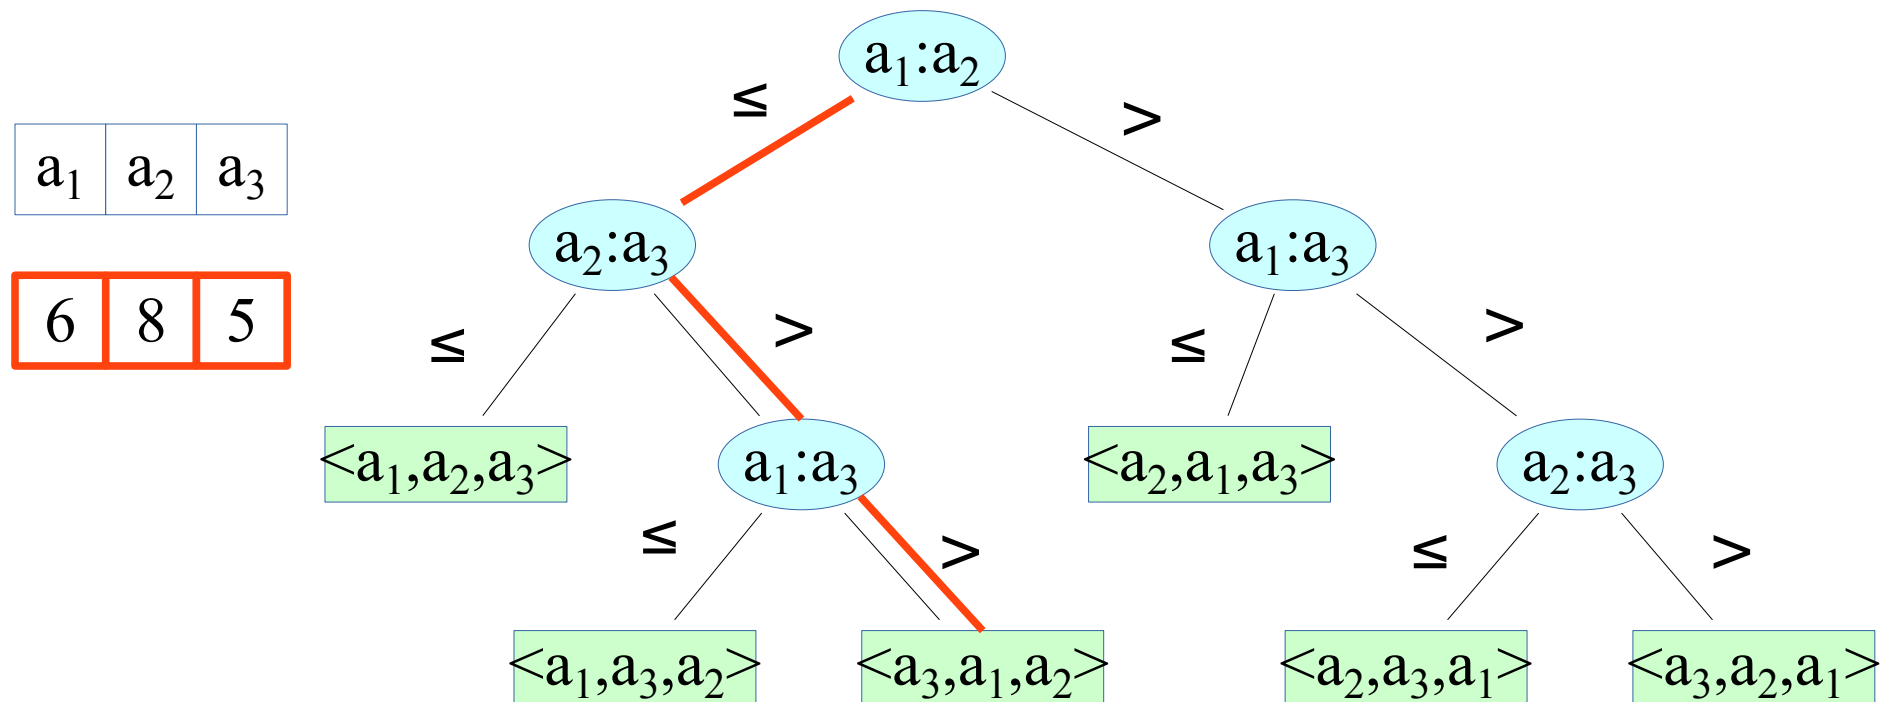
- Le operazioni di un algoritmo di ordinamento basato su confronti possono essere descritte mediante un albero di decisione
 - Ogni nodo indica una coppia di elementi da confrontare
 - Le foglie indicano i possibili ordinamenti risultanti dai confronti
- Es. Insertion Sort



Algoritmi di ordinamento



- L'esecuzione di un algoritmo corrisponde a tracciare un percorso dalla radice ad una foglia
- Ci devono essere *almeno* $n!$ foglie *raggiungibili* dalla radice
 - $n!$ è il numero di permutazioni di n elementi



Limite inferiore per il caso peggiore



- Il numero di confronti effettuati da un algoritmo nel caso peggiore è dato dalla lunghezza del più lungo percorso dalla radice dell'albero di decisione ad una foglia
 - *Ovvero dall'altezza dell'albero di decisione*
- Un limite inferiore per il tempo di esecuzione nel caso peggiore di un qualunque algoritmo basato su confronti è dato dal **limite inferiore per l'altezza di tutti gli alberi di decisione in cui ogni permutazione appare come una foglia raggiungibile dalla radice**

- Teorema
- *Qualunque algoritmo di ordinamento basato su confronti richiede $\Omega(n \lg n)$ confronti nel caso peggiore*
- Indichiamo con **h** l'altezza e con **l** il numero di foglie raggiungibili dell'albero di decisione
- $n! \leq l \leq 2^h$ (un albero binario di altezza h ha al più 2^h foglie)
- Prendendo i logaritmi (funzione crescente)
- $h \geq \lg(n!) = \Theta(n \lg n) \Rightarrow h = \Omega(n \lg n)$

Limite inferiore per il caso peggiore



$$h \geq \lg(n!) = \Theta(n \lg n) \Rightarrow h = \Omega(n \lg n)$$

$$\begin{aligned} \lg(n!) &= \lg(n(n-1)(n-2)\dots) = \sum_{i=1}^n \lg(i) \\ &\geq \sum_{i=\frac{n}{2}}^n \lg(i) \\ &\geq \sum_{i=\frac{n}{2}}^n \lg\left(\frac{n}{2}\right) = \sum_{i=\frac{n}{2}}^n (\lg(n) - \lg(2)) = \sum_{i=\frac{n}{2}}^n (\lg(n) - 1) \\ &= \frac{n}{2} \lg(n) - \frac{n}{2} = \Omega(n \lg(n)) \end{aligned}$$

O, Equivalentemente, dall'approssimazione di Stirling:

$$n! \sim \sqrt{2\pi n} \left(\frac{n}{e}\right)^n > \left(\frac{n}{e}\right)^n \Rightarrow \lg(n!) > n(\lg(n) - \lg(e)) = \Omega(n \lg(n))$$

Counting sort



- Assume che gli elementi da ordinare siano interi compresi tra 0 e k
- Approccio
 - Per ciascun intero i compreso tra 0 e k , si contano quanti elementi *pari* ad i ci sono nel vettore da ordinare
 - Per ciascun intero i compreso tra 0 e k , si determinano quanti elementi *minori o uguali* ad i ci sono nel vettore da ordinare
 - Ciò ci indica in che posizione deve stare ciascun elemento
- Counting sort utilizza due vettori di appoggio
 - B , di lunghezza n , che mantiene i valori ordinati
 - C , di lunghezza $k+1$, che indica le occorrenze di ciascun valore compreso tra 0 e k

Counting sort



•Es. Valori interi tra 0 e $k=5$

| | | | | | | | | |
|---|---|---|---|---|---|---|---|---|
| A | 2 | 5 | 3 | 0 | 2 | 3 | 0 | 3 |
|---|---|---|---|---|---|---|---|---|

| | | | | | | | | |
|---|---|---|---|---|---|---|---|---|
| | 1 | 2 | 3 | 4 | 5 | 6 | 7 | 8 |
| B | 0 | 0 | 2 | 2 | 3 | 3 | 3 | 5 |

| | | | | | | |
|---|---|---|---|---|---|---|
| | 0 | 1 | 2 | 3 | 4 | 5 |
| C | 0 | 2 | 2 | 4 | 7 | 7 |

Counting-Sort (A,B,k)

for $i \leftarrow 0$ to k

do $C[i] \leftarrow 0$

for $j \leftarrow 1$ to $\text{length}[A]$

do $C[A[j]] \leftarrow C[A[j]] + 1$

// $C[i]$ è il numero di occorrenze di i

for $i \leftarrow 1$ to k

do $C[i] \leftarrow C[i] + C[i-1]$

// $C[i]$ è il numero di elementi $\leq i$

for $j \leftarrow \text{length}[A]$ downto 1

do $B[C[A[j]]] \leftarrow A[j]$

$C[A[j]] \leftarrow C[A[j]] - 1$

Counting sort




- Tempo di esecuzione $\Theta(n+k)$
- Nella pratica, counting sort si usa quando $k=O(n)$
 - In tal caso, il tempo di esecuzione è $\Theta(n)$
- **Non** è un algoritmo di ordinamento basato su confronti
- Non ordina sul posto
- **È stabile**
 - Gli elementi di pari valore si presentano nel vettore risultato nello stesso ordine in cui si trovano nel vettore di partenza

Radix sort



- Assume che gli elementi da ordinare **siano rappresentati su d cifre**
- Ordina i valori a partire dalla cifra meno significativa
- È indispensabile utilizzare per tale ordinamento un algoritmo stabile



Radix sort



Radix-Sort (A,d)

for $i \leftarrow 1$ to d

La cifra di posto 1 è quella
meno significativa

do use a stable sort to sort array A on digit i

- La correttezza si può provare per induzione
- Se ciascuna cifra assume un numero limitato di valori (k), è opportuno scegliere counting sort
 - Tempo di esecuzione $\Theta(d(n+k))$
 - Tempo lineare se d è costante e $k=O(n)$
- Radix sort è spesso usato per ordinare informazioni aventi molteplici campi
 - es. per ordinare in base alla data, si possono effettuare tre ordinamenti stabili: in base al giorno, al mese, all'anno

Radix sort



- In generale, si ha la flessibilità di scegliere di ordinare in base a gruppi di cifre
- 0001011011101010 b bit (16), gruppi di $r \leq b$ bit (4)
 $\underbrace{\hspace{1.5cm}}_r$
- Il tempo di esecuzione di radix sort è $\Theta((b/r)(n+2^r))$
 - $d = \lceil b/r \rceil$ cifre, ciascuna di r bit $\Rightarrow 0 \leq d \leq 2^r - 1$
 - $\Theta(d(n+k)) \rightarrow \Theta((b/r)(n+2^r))$
- Dati b e n, quale valore di r minimizza il tempo di esecuzione?

Radix sort



- 0001011011101010 b bit (16), gruppi di $r \leq b$ bit (4)

 r
- Tempo di esecuzione $\Theta((b/r)(n+2^r))$
- Se $b < \lfloor \lg n \rfloor$
 - $r \leq b < \lfloor \lg n \rfloor \Rightarrow 2^r < n \Rightarrow n+2^r = \Theta(n)$
 - Convienne scegliere il valore massimo di r per minimizzare b/r
 - Per $r=b$, il tempo di esecuzione è $\Theta(n)$
- Se $b \geq \lfloor \lg n \rfloor$, la scelta migliore è $r = \lfloor \lg n \rfloor \rightarrow \Theta(bn/\lg n)$
 - Per $r > \lfloor \lg n \rfloor$, 2^r cresce più rapidamente di n \rightarrow tempo cresce
 - Per $r < \lfloor \lg n \rfloor$, b/r cresce e $n+2^r$ rimane $\Theta(n)$
- ... ovvero $r = \min \{b, \lg n\}$


- Radix sort è preferibile ad un algoritmo basato su confronto come quick sort?
 - Se, come accade spesso, $b=O(\lg n)$ e $r \approx \lg n$, il tempo di esecuzione di radix sort è $\Theta(n)$, che *appare* migliore di $\Theta(n \lg n)$
 - I fattori costanti nascosti nella notazione Θ possono differire
- Radix sort può effettuare meno passi di quicksort, ma ogni passo di radix sort può impiegare più tempo
 - Quicksort può sfruttare le cache meglio di radix sort
 - Radix sort, quando usa counting sort, non ordina sul posto e quindi richiede memoria aggiuntiva

Bucket sort



- Assume che gli elementi da ordinare siano distribuiti uniformemente sull'intervallo $[0,1)$
- L'approccio consiste in
- Dividere l'intervallo $[0,1)$ in n sottointervalli uguali e distribuire gli n elementi in tali sottointervalli
- Si devono ordinare gli elementi inseriti nello stesso sottointervallo
- Bucket sort richiede di gestire un array ausiliario $B[0..n-1]$ di liste collegate

Bucket sort



Bucket sort



Bucket-Sort (A)

$n \leftarrow \text{length}[A]$

for $i \leftarrow 1$ to n

do insert $A[i]$ into list $B[\lfloor nA[i] \rfloor]$

for $i \leftarrow 0$ to $n-1$

do sort list $B[i]$ with insertion sort

Concatenate the lists $B[0], \dots, B[n-1]$ in order

- Correttezza
 - Se $A[i] \leq A[j]$, anche $\lfloor nA[i] \rfloor \leq \lfloor nA[j] \rfloor$ quindi $A[i]$ è posto nella stessa lista di $A[j]$ o in quella precedente
- Nel primo caso, il secondo ciclo for li mette nel giusto ordine
- Nel secondo caso, la concatenazione delle liste li mette nel giusto ordine

Bucket sort



- Tempo di esecuzione
 - L'inserimento degli elementi nelle liste (primo ciclo for) richiede $\Theta(n)$
 - La concatenazione delle liste ordinate richiede $\Theta(n)$
 - E l'ordinamento delle liste?
- Indicando con n_i la variabile aleatoria che denota il numero di elementi nella lista $B[i]$:

$$T(n) = \Theta(n) + \sum_{i=0}^{n-1} O(n_i^2)$$

$$E[T(n)] = E\left[\Theta(n) + \sum_{i=0}^{n-1} O(n_i^2)\right] = \Theta(n) + \sum_{i=0}^{n-1} E\left[O(n_i^2)\right] = \Theta(n) + \sum_{i=0}^{n-1} O\left(E[n_i^2]\right)$$

Bucket sort



- Indicando con X_{ij} la variabile aleatoria che vale 1 se $A[j]$ finisce nella lista i e 0 altrimenti:

$$n_i = \sum_{j=1}^n X_{ij}$$

$$\begin{aligned} E[n_i^2] &= E\left[\left(\sum_{j=1}^n X_{ij}\right)^2\right] = E\left[\sum_{j=1}^n \sum_{k=1}^n X_{ij} X_{ik}\right] = E\left[\sum_{j=1}^n X_{ij}^2 + \sum_{1 \leq j \leq n} \sum_{\substack{1 \leq k \leq n \\ k \neq j}} X_{ij} X_{ik}\right] \\ &= \sum_{j=1}^n E[X_{ij}^2] + \sum_{1 \leq j \leq n} \sum_{\substack{1 \leq k \leq n \\ k \neq j}} E[X_{ij} X_{ik}] \end{aligned}$$

$$E[X_{ij}^2] = 1 \cdot \frac{1}{n} + 0 \cdot \left(1 - \frac{1}{n}\right) = \frac{1}{n}$$

$$E[X_{ij} X_{ik}] = E[X_{ij}] E[X_{ik}] = \frac{1}{n} \cdot \frac{1}{n} = \frac{1}{n^2}$$

Bucket sort



$$E[n_i^2] = \sum_{j=1}^n \frac{1}{n} + \sum_{1 \leq j \leq n} \sum_{\substack{1 \leq k \leq n \\ k \neq j}} \frac{1}{n^2} = n \cdot \frac{1}{n} + n(n-1) \cdot \frac{1}{n^2} = 1 + \frac{n-1}{n} = 2 - \frac{1}{n}$$

$$E[T(n)] = \Theta(n) + \sum_{i=0}^{n-1} O(E[n_i^2]) = \Theta(n) + n \cdot O\left(2 - \frac{1}{n}\right) \Theta(n)$$

- Bucket sort può ordinare in tempo lineare anche se i valori non hanno distribuzione uniforme
- È sufficiente che $\sum_{i=0}^{n-1} O(E[n_i^2])$ cresca linearmente con n